




**UNIVERSIDAD PRIVADA**  
**DOMINGO SAVIO**

**FACULTAD DE INGENIERÍA**

**CARRERA DE INGENIERÍA DE SISTEMAS**

# **INFORME DE RECONOCIMIENTO Y MIGRACION ETL AL DATA WAREHOUSE**

**Argote Gonzales Marco Ariel**

**Benavides Arancibia Jorge Enrique**

**Lujan Arispe Enrique**

**Lujan Arispe William**

**Mejillones Iraizos Rebeca**

**Valencia Vidaurre Marcos Daniel**

**Villarroel Espinoza Gustavo Ernesto**

**Cochabamba - Bolivia**

**2026**

## INDICE

|                                                           |           |
|-----------------------------------------------------------|-----------|
| <b>1. MODELO DATA WAREHOUSE (DESTINO)</b> .....           | <b>4</b>  |
| 1.1. Esquema Estrella .....                               | 4         |
| 1.2. Tipo de conexión a las fuentes de extracción .....   | 4         |
| 1.2.1. Proceso de extracción: Grupo 3 (Directa) .....     | 5         |
| 1.2.2. Proceso de extracción: Grupo 1 (Descarga CSV)..... | 5         |
| 1.2.3. Proceso de extracción: Grupo 6 (Backup SQL).....   | 6         |
| 1.3. Definición del esquema (SQL) .....                   | 7         |
| 1.4. dim_sucursal.....                                    | 8         |
| 1.5. Datos base: Solo Grupo 3 .....                       | 9         |
| <b>2. ANÁLISIS COMPARATIVO GRUPO 1 → GRUPO 3</b> .....    | <b>10</b> |
| 2.1. Esquema del Grupo 1 (Fuente) .....                   | 10        |
| 2.2. Diferencias identificadas .....                      | 10        |
| 2.3. Información a transformar.....                       | 11        |
| 2.3.1. Estrategia de IDs .....                            | 11        |
| 2.3.2. Transformación de pacientes .....                  | 11        |
| 2.3.3. Transformación de personal .....                   | 12        |
| 2.3.4. Transformación de citas .....                      | 12        |
| 2.3.5. Mapeo CIE-10 → Tipo de Diagnóstico.....            | 13        |
| 2.4. Resultado de la carga: G3 + G1 .....                 | 14        |
| 2.5. Reversibilidad .....                                 | 14        |
| <b>3. ANÁLISIS COMPARATIVO GRUPO 6 → GRUPO 3</b> .....    | <b>15</b> |
| 3.1. Esquema del Grupo 6 (Fuente) .....                   | 15        |
| 3.2. Diferencias identificadas .....                      | 16        |
| 3.3. Información a transformar.....                       | 16        |
| 3.3.1. Estrategia de IDs .....                            | 16        |
| 3.3.2. Extracción del dump SQL.....                       | 17        |
| 3.3.3. Transformación de pacientes .....                  | 17        |
| 3.3.4. Transformación de personal .....                   | 18        |
| 3.3.5. Transformación de citas y diagnósticos .....       | 18        |
| 3.3.6. Mapeo de Especialidades (24 → 15) .....            | 19        |

|                                                                  |           |
|------------------------------------------------------------------|-----------|
| 3.4. Resultado de la carga: G3 + G6 .....                        | 20        |
| 3.5. Reversibilidad .....                                        | 20        |
| <b>4. ANÁLISIS COMPARATIVO GRUPO 1 Y GRUPO 6 → GRUPO 3 .....</b> | <b>21</b> |
| 4.1. Resultado final del DW.....                                 | 21        |
| 4.2. Distribución porcentual.....                                | 21        |
| 4.3. Verificación de integridad .....                            | 24        |
| 4.4. ETL al DW .....                                             | 25        |
| <b>5. CONCLUSIONES .....</b>                                     | <b>27</b> |

## 1. MODELO DATA WAREHOUSE (DESTINO)

### 1.1. Esquema Estrella

El Data Warehouse utiliza un modelo estrella con snowflake parcial (dim\_sucursal como subdimensión de dim\_paciente). Cada fila de fact\_atenciones representa un evento de diagnóstico dentro de una cita médica.

dim\_sucursal — dim\_paciente — fact\_atenciones — dim\_medico

| Tabla           | Tipo         | Columnas | Descripción                                 |
|-----------------|--------------|----------|---------------------------------------------|
| dim_sucursal    | Subdimensión | 3        | Fuente/sucursal de los datos (G3, G1, G6)   |
| dim_paciente    | Dimensión    | 11       | Datos del paciente + FK a dim_sucursal      |
| dim_medico      | Dimensión    | 9        | Datos del médico con especialidad           |
| fact_atenciones | Hechos       | 17       | Diagnóstico + cita + dimensiones temporales |

### 1.2. Tipo de conexión a las fuentes de extracción

| Fuente           | Tipo de conexión    | Método                                                |
|------------------|---------------------|-------------------------------------------------------|
| Grupo 3 (propio) | Directa (localhost) | Consulta SQL local al contenedor Docker (puerto 5432) |
| Grupo 1          | Descarga CSV        | Conexión psql a Supabase → \copy TO                   |

|         |                   |                                                                        |
|---------|-------------------|------------------------------------------------------------------------|
|         |                   | STDOUT → CSV →<br>importación staging                                  |
| Grupo 6 | Backup (dump SQL) | Archivo dump<br>PostgreSQL →<br>conversión encoding →<br>carga staging |

### 1.2.1. Proceso de extracción: Grupo 3 (Directa)

Los datos del Grupo 3 residen en la misma base de datos destino (clinica\_db).

La carga al DW se realiza mediante consultas COPY directas:

```
-- Extracción directa desde el contenedor 'db'
docker compose exec -T db psql -U clinica_user -d clinica_db -c "
COPY (
    SELECT p.CI, p.Nombre, p.Fecha_Nacimiento, ...
    FROM PERSONA p
    JOIN ZONA z ON z.ID_Zona = p.ID_Zona
    WHERE p.Matricula IS NULL
) TO STDOUT WITH (FORMAT csv)
" > /tmp/dw_dim_paciente.csv
```

### 1.2.2. Proceso de extracción: Grupo 1 (Descarga CSV)

Se conecta al servidor Supabase del Grupo 1 usando psql con cadena de conexión PostgreSQL. Se descargan 4 tablas a archivos CSV locales mediante \copy TO STDOUT, que luego se importan a tablas staging en nuestra base de datos:

```
# Cadena de conexión al servidor remoto (Supabase)
G1_CONN="postgresql://usuario1.<host>:<pass>@<ip>:5432/postgres?sslm
ode=require"

# Exportar cada tabla a CSV via consulta remota
docker compose exec -T db psql "$G1_CONN" -c "
```

```

\copy (SELECT paciente_id, nombre, fecha_nacimiento, genero
      FROM pacientes ORDER BY paciente_id)
      TO STDOUT WITH (FORMAT csv, HEADER true)
" > /tmp/etl_g1_csv/g1_pacientes.csv

# Se repite para: personal, atenciones, diagnosticos

# Copiar CSVs al contenedor e importar a tablas staging
docker cp g1_pacientes.csv <contenedor>:/tmp/g1_pacientes.csv
docker compose exec -T db psql -U clinica_user -d clinica_db \
  < etl/grupo1/01-extract.sql -- CREATE TABLE stg_g1_* + \copy FROM

```

### 1.2.3. Proceso de extracción: Grupo 6 (Backup SQL)

El Grupo 6 entrega sus datos como dump SQL (PostgreSQL 17, encoding WIN1252). El proceso de carga sigue estos pasos:

```

# 1. Crear tablas staging que replican el esquema G6
docker compose exec -T db psql -U clinica_user -d clinica_db \
  < etl/grupo6_v2/01-extract.sql
  -- Crea: stg_g6_persona, stg_g6_paciente, stg_g6_personal,
  --      stg_g6_cita_medica, stg_g6_diagnostico, stg_g6_receta, ...

# 2. Conversión de encoding y renombrado de tablas
iconv -f WINDOWS-1252 -t UTF-8 hospital_db_inserts.sql | \
  sed 's/INSERT INTO public\.\([a-z_]*\) /INSERT INTO stg_g6_\1/g' | \
  grep '^INSERT INTO stg_g6_\(persona\|paciente\|personal\|...\)' \
  > g6v2_inserts_staging.sql

# 3. Ejecutar inserts en staging
docker compose exec -T db psql -U clinica_user -d clinica_db \
  -f /tmp/g6v2_inserts_staging.sql

```

### 1.3. Definición del esquema (SQL)

Creación de las tablas del DW:

```
CREATE TABLE dim_sucursal (  
    sucursal_key SERIAL PRIMARY KEY,  
    nombre      VARCHAR(100) NOT NULL,  
    host        VARCHAR(200) NOT NULL  
);
```

```
CREATE TABLE dim_paciente (  
    paciente_key SERIAL PRIMARY KEY,  
    sucursal_key INT REFERENCES dim_sucursal(sucursal_key),  
    ci           VARCHAR(20) NOT NULL,  
    nombre      VARCHAR(150) NOT NULL,  
    fecha_nacimiento DATE,  
    sexo        CHAR(1),  
    direccion   VARCHAR(255),  
    telefono    VARCHAR(20),  
    zona        VARCHAR(100),  
    ciudad     VARCHAR(100),  
    grupo_origen VARCHAR(10) NOT NULL  
);
```

```
CREATE TABLE dim_medico (  
    medico_key SERIAL PRIMARY KEY,  
    ci          VARCHAR(20) NOT NULL,  
    nombre     VARCHAR(150) NOT NULL,  
    matricula  VARCHAR(50),  
    sexo       CHAR(1),  
    especialidad VARCHAR(100),  
    zona       VARCHAR(100),  
    ciudad     VARCHAR(100),
```

```

    grupo_origen VARCHAR(10) NOT NULL
);

CREATE TABLE fact_atenciones (
    atencion_key    SERIAL PRIMARY KEY,
    paciente_key    INT NOT NULL REFERENCES
dim_paciente(paciente_key),
    medico_key      INT NOT NULL REFERENCES
dim_medico(medico_key),
    fecha_cita      DATE NOT NULL,
    anio            INT NOT NULL,
    mes            INT NOT NULL,
    trimestre       INT NOT NULL,
    dia_semana      VARCHAR(15) NOT NULL,
    hora            TIME,
    estado          VARCHAR(50),
    numero_turno    INT,
    descripcion      TEXT,
    observaciones    TEXT,
    tipo_procedimiento VARCHAR(100),
    tipo_diagnostico VARCHAR(100),
    categoria        VARCHAR(100),
    grupo_origen     VARCHAR(10) NOT NULL
);

```

#### 1.4. dim\_sucursal

| sucursal_key | nombre  | host                                           |
|--------------|---------|------------------------------------------------|
| 1            | Grupo 3 | localhost:5433<br>(PostgreSQL -<br>clinica_db) |

|   |         |                                                |
|---|---------|------------------------------------------------|
| 2 | Grupo 1 | aws-0-us-west-2.pooler.supabase.com (Supabase) |
| 3 | Grupo 6 | PostgreSQL 17 (dump hospital_db)               |

### 1.5. Datos base: Solo Grupo 3

El punto de partida es el DW cargado únicamente con datos del Grupo 3 (nuestro modelo original).

| Tabla DW        | Registros (solo G3) |
|-----------------|---------------------|
| dim_sucursal    | 3 (pre-cargadas)    |
| dim_paciente    | 4,500               |
| dim_medico      | 500                 |
| fact_atenciones | 15,000              |

## 2. ANÁLISIS COMPARATIVO GRUPO 1 → GRUPO 3

### 2.1. Esquema del Grupo 1 (Fuente)

Base de datos alojada en Supabase (AWS us-west-2). 4 tablas planas sin normalización de catálogos.

| Tabla        | Registros | Columnas principales                                                  |
|--------------|-----------|-----------------------------------------------------------------------|
| pacientes    | 50,000    | paciente_id, nombre, fecha_nacimiento, genero                         |
| personal     | 50,000    | personal_id, nombre, cargo, especialidad                              |
| atenciones   | 50,000    | atencion_id, paciente_id, personal_id, fecha_atencion, estado, motivo |
| diagnosticos | 68,123    | diagnostico_id, atencion_id, codigo_cie10, descripcion, severidad     |

### 2.2. Diferencias identificadas

| Aspecto        | Grupo 3        | Grupo 1   | Observación                    |
|----------------|----------------|-----------|--------------------------------|
| Identificación | CI obligatorio | Sin CI    | Se genera marcador G1-PAC-{id} |
| Ubicación      | zona + ciudad  | No existe | Se asigna zona especial ID=99  |

|              |                       |                 |                                  |
|--------------|-----------------------|-----------------|----------------------------------|
| Especialidad | ID normalizado (15)   | Texto libre     | JOIN por nombre con ESPECIALIDAD |
| Diagnóstico  | FK → TIPO_DIAGNOSTICO | Código CIE-10   | Mapeo CIE-10 → categoría         |
| Fecha/hora   | fecha_cita + hora     | timestamp único | Se extrae DATE y TIME            |
| Turno        | numero_turno          | No existe       | ROW_NUMBER() por día+médico      |
| Recetas      | Tabla RECETA          | No tiene        | No se migran recetas             |

## 2.3. Información a transformar

### 2.3.1. Estrategia de IDs

| Entidad                    | Rango original | Offset   | Rango destino     |
|----------------------------|----------------|----------|-------------------|
| Pacientes → PERSONA        | 1 - 50,000     | +100,000 | 100,001 - 150,000 |
| Personal → PERSONA         | 1 - 50,000     | +200,000 | 200,001 - 250,000 |
| Atenciones → CITA_MEDICA   | 1 - 50,000     | +100,000 | 100,001 - 150,000 |
| Diagnósticos → DIAGNOSTICO | 1 - 68,123     | +100,000 | 100,001 - 168,123 |

### 2.3.2. Transformación de pacientes

Extracción y transformación de pacientes del G1:

```
SELECT
    paciente_id + 100000      AS id_persona,
```

```

'G1-PAC-' || paciente_id    AS ci,
nombre                      AS nombre,
fecha_nacimiento           AS fecha_nacimiento,
genero                     AS sexo,
'Sin dato (Grupo 1)'      AS direccion,
'Sin dato (Grupo 1)'      AS telefono,
NULL                      AS matricula,
99                         AS id_zona,
NULL                      AS id_especialidad
INTO tfm_g1_persona_pacientes
FROM stg_g1_pacientes;

```

### 2.3.3. Transformación de personal

```

SELECT
personal_id + 200000      AS id_persona,
'G1-PER-' || personal_id  AS ci,
nombre, '1900-01-01' AS fecha_nacimiento,
'X' AS sexo,
'G1-MAT-' || personal_id  AS matricula,
99                        AS id_zona,
e.ID_Especialidad        AS id_especialidad
INTO tfm_g1_persona_personal
FROM stg_g1_personal p
LEFT JOIN ESPECIALIDAD e ON e.Nombre = p.especialidad;

```

### 2.3.4. Transformación de citas

```

SELECT
atencion_id + 100000      AS id_cita,
fecha_atencion::DATE      AS fecha_registro,
fecha_atencion::DATE      AS fecha_cita,
fecha_atencion::TIME      AS hora,
ROW_NUMBER() OVER(

```

```

PARTITION BY fecha_atencion::DATE, personal_id
ORDER BY fecha_atencion
)
AS numero_turno,
estado,
paciente_id + 100000 AS id_paciente,
personal_id + 200000 AS id_medico
INTO tfm_g1_cita_medica
FROM stg_g1_atenciones;

```

### 2.3.5. Mapeo CIE-10 → Tipo de Diagnóstico

Los códigos CIE-10 del G1 se mapearon a categorías diagnósticas del G3:

| Código CIE-10     | Diagnóstico               | Categoría asignada |
|-------------------|---------------------------|--------------------|
| I10               | Hipertensión esencial     | Clínico            |
| R10.9             | Dolor abdominal           | Clínico            |
| R51               | Cefalea                   | Clínico            |
| J02.9/J06.9/J20.9 | Infecciones respiratorias | Clínico            |
| L30.9             | Dermatitis                | Clínico            |
| M54.5             | Dolor lumbar bajo         | Por Imagen         |
| E78.5             | Hiperlipidemia            | Laboratorio        |
| E11.9             | Diabetes mellitus tipo 2  | Laboratorio        |
| N39.0             | Infección urinaria        | Laboratorio        |
| E66.9             | Obesidad                  | Nutricional        |
| K29.5             | Gastritis crónica         | Endoscópico        |
| Z00.0             | Examen general            | Ambulatorio        |
| Z71.1             | Consulta orientación      | Ambulatorio        |

#### 2.4. Resultado de la carga: G3 + G1

| Tabla DW        | Antes (G3) | + Grupo 1 | Después (Total) |
|-----------------|------------|-----------|-----------------|
| dim_paciente    | 4,500      | +87,487   | 91,987          |
| dim_medico      | 500        | +13,337   | 13,837          |
| fact_atenciones | 15,000     | +68,123   | 83,123          |

#### 2.5. Reversibilidad

El rollback elimina datos por rango de IDs y restaura secuencias:

-- Eliminar en orden de dependencias FK

```
DELETE FROM DIAGNOSTICO WHERE ID_Diagnostico BETWEEN 100001  
AND 168123;
```

```
DELETE FROM CITA_MEDICA WHERE ID_Cita BETWEEN 100001 AND  
150000;
```

```
DELETE FROM PERSONA WHERE ID_Persona BETWEEN 100001 AND  
250000;
```

-- Restaurar secuencias

```
SELECT setval('persona_id_persona_seq', (SELECT MAX(ID_Persona)  
FROM PERSONA));
```

### 3. ANÁLISIS COMPARATIVO GRUPO 6 → GRUPO 3

#### 3.1. Esquema del Grupo 6 (Fuente)

Esquema PostgreSQL 17 normalizado en 3NF. 25 tablas totales (incluye catálogos y extensiones del Grupo 2), de las cuales 9 son relevantes para la migración.

| Tabla            | Registros | Columnas principales                                                                    |
|------------------|-----------|-----------------------------------------------------------------------------------------|
| persona          | 35,331    | id_persona, ci, nombre, fecha_nacimiento, sexo, direccion, telefono, matricula, id_zona |
| paciente         | 34,500    | id_paciente, id_persona (tabla de rol)                                                  |
| personal         | 831       | id_personal, id_persona, id_especialidad, id_cargo, id_turno                            |
| especialidad     | 24        | id_especialidad, nombre                                                                 |
| zona             | 30        | id_zona, nombre, ciudad                                                                 |
| tipo_diagnostico | 25        | id_tipo_diagnostico, nombre, categoria                                                  |
| cita_medica      | 70,000    | id_cita, fecha_registro, fecha_cita, hora, numero_turno, estado                         |
| diagnostico      | 40,134    | id_diagnostico, descripcion, observaciones, tipo_procedimiento                          |

|        |        |                                                                |
|--------|--------|----------------------------------------------------------------|
| receta | 40,134 | id_receta,<br>medicamentos,<br>indicaciones,<br>id_diagnostico |
|--------|--------|----------------------------------------------------------------|

### 3.2. Diferencias identificadas

| Aspecto          | Grupo 3              | Grupo 6                                | Observación                               |
|------------------|----------------------|----------------------------------------|-------------------------------------------|
| Personas         | PERSONA<br>unificada | persona +<br>paciente +<br>personal    | Roles en tablas<br>separadas              |
| Especialidades   | 15 registros         | 24 registros                           | 9 adicionales sin<br>equivalente en<br>G3 |
| Zonas            | 20 zonas             | 30 zonas                               | Se asigna zona<br>genérica ID=98          |
| Catálogos extra  | No existen           | 9 tablas cat_*                         | No relevantes<br>para el DW               |
| Extensiones      | No existen           | pago,<br>medicamento,<br>procedimiento | Fuera del alcance<br>del DW               |
| Tipo diagnóstico | IDs 1-25             | IDs 1-25<br>(coinciden)                | Mapeo directo                             |

### 3.3. Información a transformar

#### 3.3.1. Estrategia de IDs

| Entidad                | Rango original | Offset   | Rango destino        |
|------------------------|----------------|----------|----------------------|
| Pacientes<br>(persona) | 1 - 34,500     | +300,000 | 300,001 -<br>334,500 |

|                       |            |          |                      |
|-----------------------|------------|----------|----------------------|
| Personal<br>(persona) | 1 - 831    | +600,000 | 600,001 -<br>600,831 |
| Citas                 | 1 - 70,000 | +300,000 | 300,001 -<br>370,000 |
| Diagnósticos          | 1 - 40,134 | +300,000 | 300,001 -<br>340,134 |
| Recetas               | 1 - 40,134 | +300,000 | 300,001 -<br>340,134 |

### 3.3.2. Extracción del dump SQL

El G6 entrega sus datos como dump PostgreSQL (encoding WIN1252). Se convierte encoding y se renombran tablas a staging:

```
iconv -f WINDOWS-1252 -t UTF-8 hospital_db_inserts.sql | \
sed 's/INSERT INTO public\.[a-z_]*\)/INSERT INTO stg_g6_1/g' | \
grep '^INSERT INTO stg_g6_(persona|paciente|personal|...)' | \
> g6v2_inserts_staging.sql
```

### 3.3.3. Transformación de pacientes

Se identifican pacientes mediante JOIN con la tabla de rol paciente:

```
SELECT
  p.id_persona + 300000      AS id_persona,
  'G6-PAC-' || p.id_persona AS ci,
  p.nombre, p.fecha_nacimiento, p.sexo,
  p.direccion, p.telefono,
  NULL                      AS matricula,
  98                        AS id_zona
INTO tfm_g6_persona_pacientes
FROM stg_g6_persona p
INNER JOIN stg_g6_paciente pac ON pac.id_persona = p.id_persona;
```

### 3.3.4. Transformación de personal

```
SELECT
    p.id_persona + 600000      AS id_persona,
    'G6-MED-' || p.id_persona  AS ci,
    p.nombre, p.fecha_nacimiento, p.sexo,
    p.direccion, p.telefono,
    'G6-MAT-' || per.id_personal AS matricula,
    98                        AS id_zona,
    COALESCE(me.g3_id, 1)      AS id_especialidad
INTO tfm_g6_persona_personal
FROM stg_g6_persona p
INNER JOIN stg_g6_personal per ON per.id_persona = p.id_persona
LEFT JOIN tfm_g6_mapeo_especialidad me ON me.g6_id =
per.id_especialidad;
```

### 3.3.5. Transformación de citas y diagnósticos

-- CITA\_MEDICA: offsets en paciente y médico

```
SELECT
    c.id_cita + 300000      AS id_cita,
    c.fecha_registro, c.fecha_cita, c.hora,
    c.numero_turno, c.estado,
    c.id_paciente + 300000  AS id_paciente,
    c.id_medico + 600000    AS id_medico
INTO tfm_g6_cita_medica
FROM stg_g6_cita_medica c;
```

-- DIAGNOSTICO: tipo\_diagnostico IDs 1-25 coinciden con G3

```
SELECT
    d.id_diagnostico + 300000  AS id_diagnostico,
    d.descripcion, d.observaciones, d.tipo_procedimiento,
    d.id_cita + 300000        AS id_cita,
```

```

d.id_tipo_diagnostico      AS id_tipo_diagnostico
INTO tfm_g6_diagnostico
FROM stg_g6_diagnostico d;

```

### 3.3.6. Mapeo de Especialidades (24 → 15)

Las especialidades 1-15 coinciden con G3 (mapeo directo). Las 9 adicionales (16-24) se remapearon por afinidad clínica:

| ID G6 | Especialidad G6   | ID G3 | Especialidad G3  | Justificación                        |
|-------|-------------------|-------|------------------|--------------------------------------|
| 16    | Medicina Interna  | 1     | Medicina General | Subespecialidad de medicina general  |
| 17    | Cirugía General   | 7     | Traumatología    | Área quirúrgica más cercana          |
| 18    | Radiología        | 1     | Medicina General | Servicio de apoyo diagnóstico        |
| 19    | Anestesiología    | 1     | Medicina General | Servicio transversal                 |
| 20    | Nefrología        | 10    | Urología         | Misma área anatómica (sistema renal) |
| 21    | Hematología       | 1     | Medicina General | Subespecialidad de medicina interna  |
| 22    | Reumatología      | 7     | Traumatología    | Sistema musculoesquelético           |
| 23    | Infectología      | 1     | Medicina General | Subespecialidad de medicina interna  |
| 24    | Medicina Familiar | 1     | Medicina General | Equivalente funcional                |

### 3.4. Resultado de la carga: G3 + G6

| Tabla DW        | Antes (G3) | + Grupo 6 | Después (Total) |
|-----------------|------------|-----------|-----------------|
| dim_paciente    | 4,500      | +34,500   | 39,000          |
| dim_medico      | 500        | +831      | 1,331           |
| fact_atenciones | 15,000     | +40,134   | 55,134          |

### 3.5. Reversibilidad

-- Eliminar datos G6 por rango de IDs

```
DELETE FROM RECETA WHERE ID_Receta >= 300001;
```

```
DELETE FROM DIAGNOSTICO WHERE ID_Diagnostico >= 300001;
```

```
DELETE FROM CITA_MEDICA WHERE ID_Cita >= 300001;
```

```
DELETE FROM PERSONA WHERE ID_Persona BETWEEN 300001 AND  
400000;
```

```
DELETE FROM PERSONA WHERE ID_Persona BETWEEN 600001 AND  
700000;
```

-- Limpiar staging y transformación

```
DROP TABLE IF EXISTS stg_g6_ * CASCADE;
```

```
DROP TABLE IF EXISTS tfm_g6_ * CASCADE;
```


-- Restaurar secuencias

```
SELECT setval('persona_id_persona_seq', (SELECT MAX(ID_Persona)  
FROM PERSONA));
```

4. ANÁLISIS COMPARATIVO GRUPO 1 Y GRUPO 6 → GRUPO 3

4.1. Resultado final del DW


Con ambos grupos cargados, el DW contiene datos de las 3 fuentes:



| Tabla DW        | G3     | G1     | G6     | Total   |
|-----------------|--------|--------|--------|---------|
| dim_sucursal    | —      | —      | —      | 3       |
| dim_paciente    | 4,500  | 87,487 | 34,500 | 126,487 |
| dim_medico      | 500    | 13,337 | 831    | 14,668  |
| fact_atenciones | 15,000 | 68,123 | 40,134 | 123,257 |


4.2. Distribución porcentual

Pacientes por sucursal:




| Sucursal | Pacientes | %     |
|----------|-----------|-------|
| Grupo 3  | 4,500     | 3.6%  |
| Grupo 1  | 87,487    | 69.2% |
| Grupo 6  | 34,500    | 27.3% |

Atenciones (hechos) por grupo:



| Grupo | Atenciones | %     |
|-------|------------|-------|
| G3    | 15,000     | 12.2% |
| G1    | 68,123     | 55.3% |
| G6    | 40,134     | 32.6% |

Médicos por grupo:



| Grupo | Médicos | %     |
|-------|---------|-------|
| G3    | 500     | 3.4%  |
| G1    | 13,337  | 90.9% |
| G6    | 831     | 5.7%  |

#### 4.3. Verificación de integridad

| Verificación                           | Resultado |
|----------------------------------------|-----------|
| Pacientes sin sucursal asignada        | 0         |
| Atenciones sin paciente válido (FK)    | 0         |
| Atenciones sin médico válido (FK)      | 0         |
| Registros huérfanos en fact_atenciones | 0         |

#### 4.4. ETL al DW

La carga al modelo estrella se ejecuta en 6 pasos. Extracción de dim\_paciente:

```
SELECT p.Cl, p.Nombre, p.Fecha_Nacimiento, p.Sexo,
       p.Direccion, p.Telefono, z.Nombre, z.Ciudad,
       CASE
         WHEN p.Cl LIKE 'G1-%' THEN 'G1'
         WHEN p.Cl LIKE 'G6-%' THEN 'G6'
         ELSE 'G3'
       END AS grupo_origen
FROM PERSONA p
JOIN ZONA z ON z.ID_Zona = p.ID_Zona
WHERE p.Matricula IS NULL;
```

Asignación de sucursal\_key post-carga:

```
UPDATE dim_paciente SET sucursal_key = CASE grupo_origen
  WHEN 'G3' THEN 1
  WHEN 'G1' THEN 2
  WHEN 'G6' THEN 3
END;
```

Carga de fact\_atenciones (combina DIAGNOSTICO + CITA\_MEDICA + TIPO\_DIAGNOSTICO):

```
SELECT pac.Cl, med.Cl, c.Fecha_Cita,
       EXTRACT(YEAR FROM c.Fecha_Cita)::INT AS anio,
       EXTRACT(MONTH FROM c.Fecha_Cita)::INT AS mes,
       EXTRACT(QUARTER FROM c.Fecha_Cita)::INT AS trimestre,
       TRIM(TO_CHAR(c.Fecha_Cita, 'Day')) AS dia_semana,
       c.Hora, c.Estado, c.Numero_Turno,
       d.Descripcion, d.Observaciones,
       d.Tipo_Procedimiento, td.Nombre, td.Categoria,
       grupo_origen
FROM DIAGNOSTICO d
```

```
JOIN CITA_MEDICA c ON c.ID_Cita = d.ID_Cita
JOIN PERSONA pac ON pac.ID_Persona = c.ID_Paciente
JOIN PERSONA med ON med.ID_Persona = c.ID_Medico
JOIN TIPO_DIAGNOSTICO td ON td.ID_Tipo_Diagnostico =
d.ID_Tipo_Diagnostico;
```

Resolución de FK en el DW mediante JOIN por CI:

```
INSERT INTO fact_atenciones (...)
SELECT dp.paciente_key, dm.medico_key,
       sf.fecha_cita, sf.anio, sf.mes, ...
FROM stg_fact sf
JOIN dim_paciente dp ON dp.ci = sf.paciente_ci
JOIN dim_medico dm ON dm.ci = sf.medico_ci;
```

## 5. CONCLUSIONES

Se implementó un Data Warehouse con modelo estrella (snowflake parcial por dim\_sucursal) que consolida datos de tres fuentes heterogéneas en un esquema analítico unificado.

El modelo consta de una tabla de hechos (fact\_atenciones con 123,257 registros) y tres dimensiones: dim\_paciente (126,487), dim\_medico (14,668) y dim\_sucursal (3). La dimensión sucursal permite segmentar y comparar métricas entre las fuentes de origen.

Cada fuente presentó desafíos distintos de integración: el Grupo 1 requirió mapeo de códigos CIE-10 a categorías diagnósticas y generación de identificadores sintéticos; el Grupo 6 necesitó conversión de encoding (WIN1252 → UTF-8) y remapeo de 24 especialidades a las 15 del esquema destino. En ambos casos se utilizaron offsets de IDs para evitar colisiones y scripts de rollback para garantizar la reversibilidad de cada carga.

Los tres tipos de conexión utilizados (directa local, descarga CSV desde servidor remoto y carga de backup SQL) demuestran la capacidad del proceso ETL para integrar fuentes con distintos mecanismos de acceso.

El DW resultante soporta consultas analíticas sobre especialidades, distribución temporal de atenciones, diagnósticos más frecuentes y comparativas entre sucursales, cumpliendo el objetivo de inteligencia de negocios planteado.